马悠然

电话：(+86)183-0619-9968 | 邮件：youranma2024@gmail.com

教育背景

2025.09 – 2026.12　Northwestern University　　计算机科学硕士（GPA：3.9/4.0）　　美国 伊利诺伊州 埃文斯顿

主修课程：Software Development Studio, Cryptography, CUDA Programming, Scalable Software Architectures

2021.09 – 2025.06　香港中文大学（深圳）　　计算机科学与工程学士（GPA：3.6/4.0）　　中国 广东 深圳

主修课程：数据结构，算法分析与设计，计算机体系结构，计算机网络，操作系统，数据库系统，软件工程，并行计算等

荣誉奖项：2022 年 Dean’s List，2024 年 Dean’s List，一等荣誉学士学位

实习经历

2025.11 – 2026.02　Avary.ai　　软件工程实习生　　美国 华盛顿州 西雅图（远程）

- 参与 AI 面试官产品的迭代开发，协助与客户沟通完善需求，配合完成 PR 评审、联调与测试，按节奏交付前后端功能；
- 参与面试流程优化，在模拟环节补充录音时长与静音检测逻辑，完善提示与重试引导，减少误操作带来的无效录音；
- 参与开发面试语音系统，推动 GPT 先分句 + 服务端兜底的断句切分方案，按 8–25 词粒度输出 TTS 分块，并补充 10 组模拟回答测试，支持首句就绪后优先播报，提升长回答场景下的流式输出平滑度；
- 参与构建数据整合面板，实现统计卡片、面试列表、Top 榜单及配套 API，支持面试记录分页查询、多条件筛选，并结合数据库索引与查询优化提升统计接口性能，减少全量数据加载带来的传输与渲染开销，提升页面响应速度和用户体验。

2024.05 – 2024.08　OSRAM Opto Semiconductors　　软件工程实习生　　中国 江苏 无锡

- 参与公司物料管理系统研发，将旧版 HTML 操作界面迁移至基于 Qt/C++的 PDA 应用，支持扫码录入、物料接收与库位流转等核心流程，提升产线作业便捷性；
- 对 C++请求/响应处理进行模块化封装，对接遗留 API，沉淀可复用的交互组件，提升跨模块协作效率，加速系统迭代；
- 协助 Spring Boot 后端开发，补充业务逻辑、数据库访问与接口文档，配合前端联调并负责功能说明；多次参与需求调研，并与生产部门协作梳理流程细节，支持功能迭代落地；
- 参与前端部署交接，配合完成后端阿里云环境的测试验证与上线准备，保障系统试运行与交付。

项目经历

2025.09 – 2025.12　TFT Smart Hub　　Tech Lead　　合作项目

技术栈：Vue 3 + Vite 前端，Rails RESTful API 后端，PostgreSQL 数据库；

项目内容：云顶之弈单位与阵容数据浏览、阵容编辑、基于已选单位的推荐算法；

网站： https://tft-smarthub-517534671b49.herokuapp.com

GitHub: https://github.com/NU-CS-Software-Studio-Fall-25/project-tft-smart-hub

- 在 4 人 Scrum 团队中担任 Tech Lead，推进迭代规划、任务拆分与前后端协同开发；
- 设计数据模型与 Rails MVC 接口，参与后端开发，为阵容检索与浏览提供服务端筛选、分页和索引优化，缓解数据规模增长带来的查询压力与页面卡顿；
- 负责前端核心功能开发，实现阵容搜索、编辑与推荐等功能，并通过语义化标签、ARIA 与键盘导航提升网站可访问性；
- 参与 GitHub Actions 的 CI/CD 流程建设，接入 RSpec 单元测试（29 项）和 Cucumber 集成测试（19 个场景 / 69 个步骤），完成 Heroku 部署并集成 Google OAuth、SMTP 邮件等功能。

2024.09 – 2025.01　CUDA 注意力前向计算　　个人项目

技术栈：C++，CUDA，Python；

GitHub: https://github.com/myr321/GPU-accelerated-Attention

- 基于 PyTorch C++扩展与 CUDA 实现了 Scaled Dot-Product Attention 前向计算，完成 naive、tiled 和 fused Softmax + P@V 三类自定义 kernel，并编写测试与绘图脚本，系统性比较不同优化策略的性能收益；

- 针对注意力计算的两个阶段，引入 shared memory tiling 和 warp-level reduction 两类优化；设计融合 Softmax + P@V 的 kernel，避免将概率矩阵写回全局内存，降低中间内存访问开销；
- 使用 Python 构建正确性校验与性能测试流程，验证不同版本的输出一致性；并在 RTX 2060 SUPER 环境下对 L = 64 – 1024、d = 32 – 256 的输入完成 benchmark，最佳自定义实现相较 CPU baseline 取得约 3 倍加速。

其他信息

英语能力：TOEFL 107、GRE 325；

专业技能：

熟练掌握 Java、C++、Python、JS、SQL 等语言；

熟悉 Spring Boot、Vue 3、Qt、Rails、Express 等框架；

熟练掌握常用算法与数据结构，能够在功能实现、系统设计及性能优化中进行合理选型与应用；

熟悉数据库设计范式，具备 MySQL 数据库建模、管理与性能优化经验，并具备后端服务与服务器端部署开发实践；

熟悉 AWS 云端部署，能够使用 EC2、Lambda 等服务完成应用上线、接口部署与基础环境配置；

熟悉并行计算基本原理与性能优化方法，了解 MPI、OpenMP、CUDA 等并行编程框架，具备并行程序设计与实现能力。